# Машинное обучение




## Занятие 3. Линейная классификация

ФАЛТ МФТИ · осенний семестр 2026/27 · Патрацкий Максим

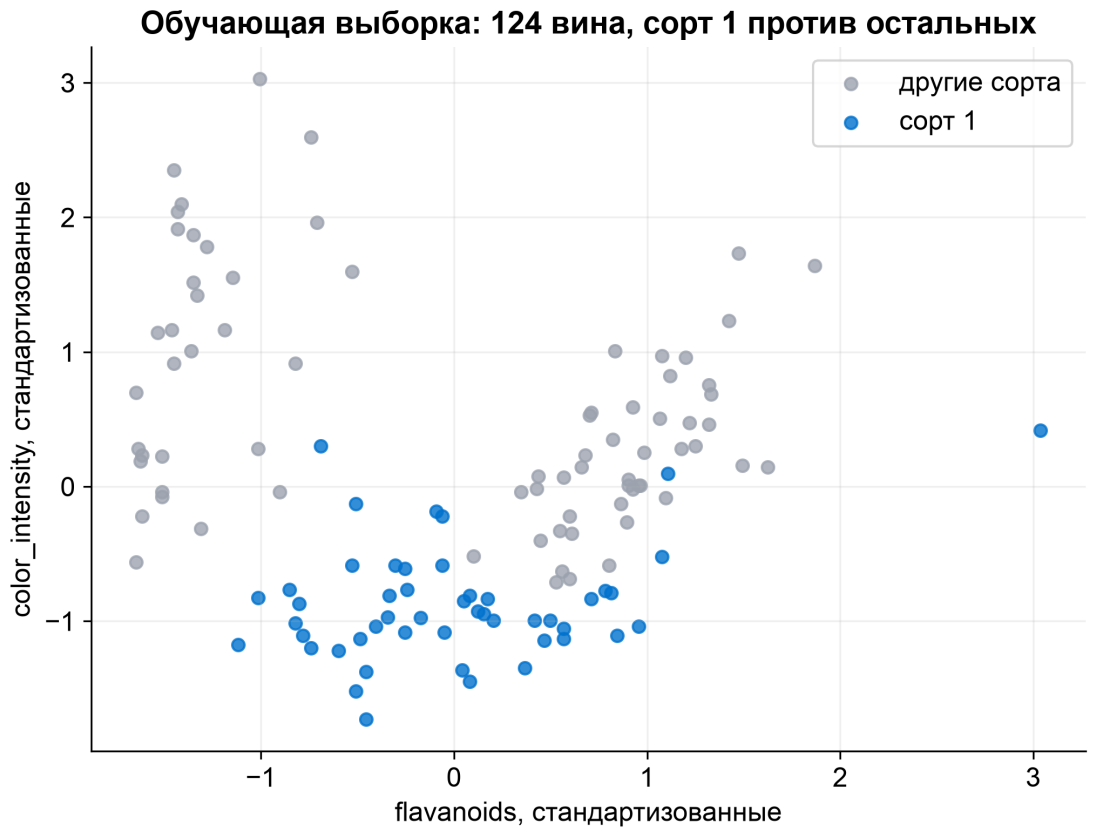
# 01

# Задача: сорт 1 или нет

два признака, два класса



# Обучающая выборка



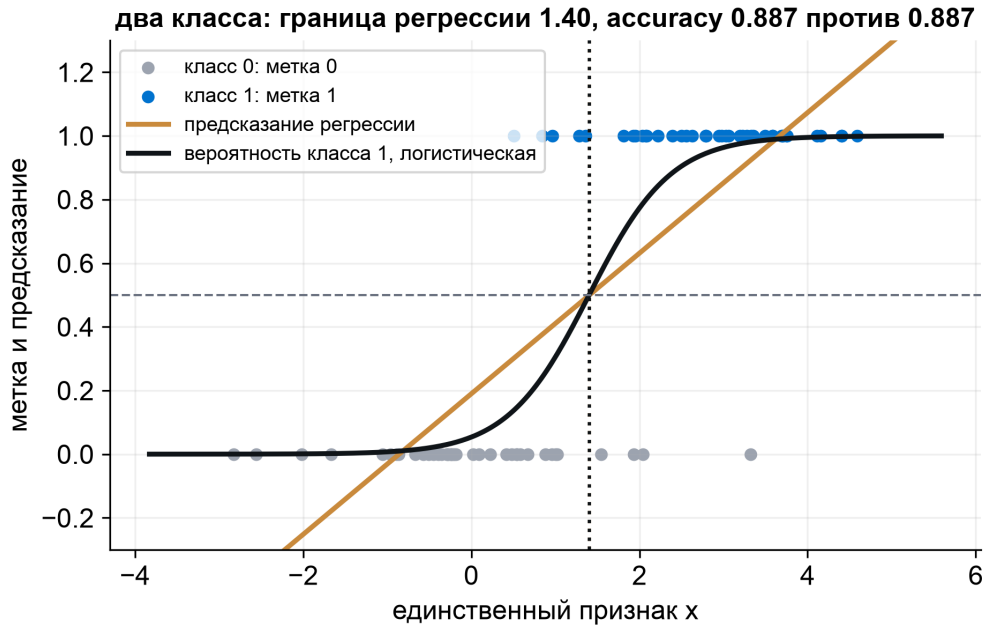
# 02

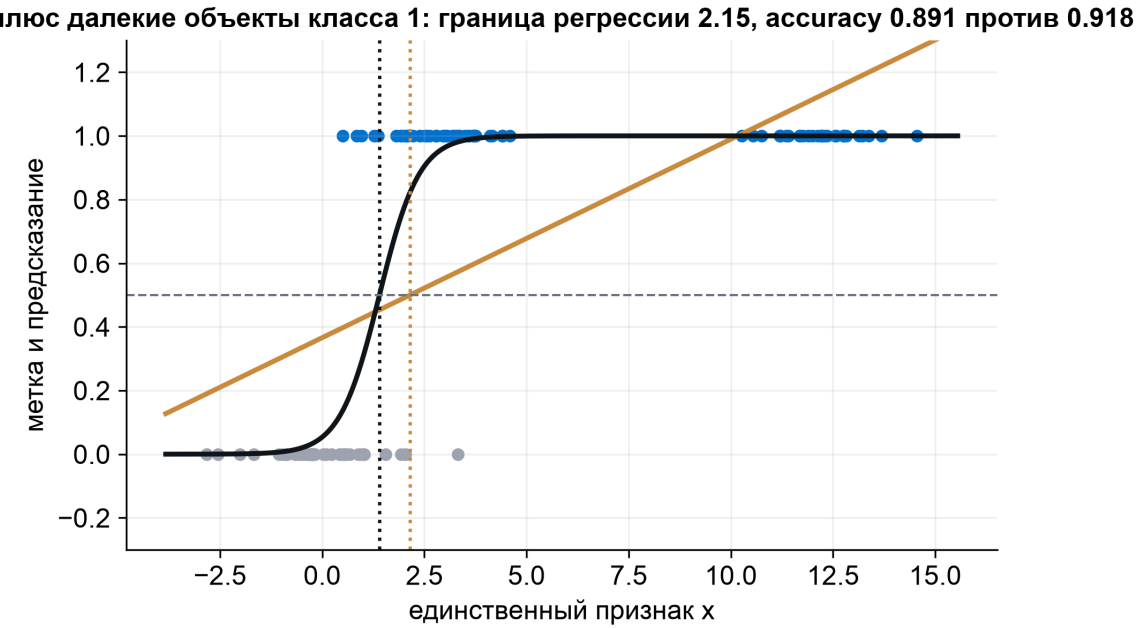
# Почему не линейная регрессия

метки 0 и 1 — тоже числа



# Далекие объекты разворачивают прямую



# 03

# Линейный классификатор и отступ

одна величина на все занятие

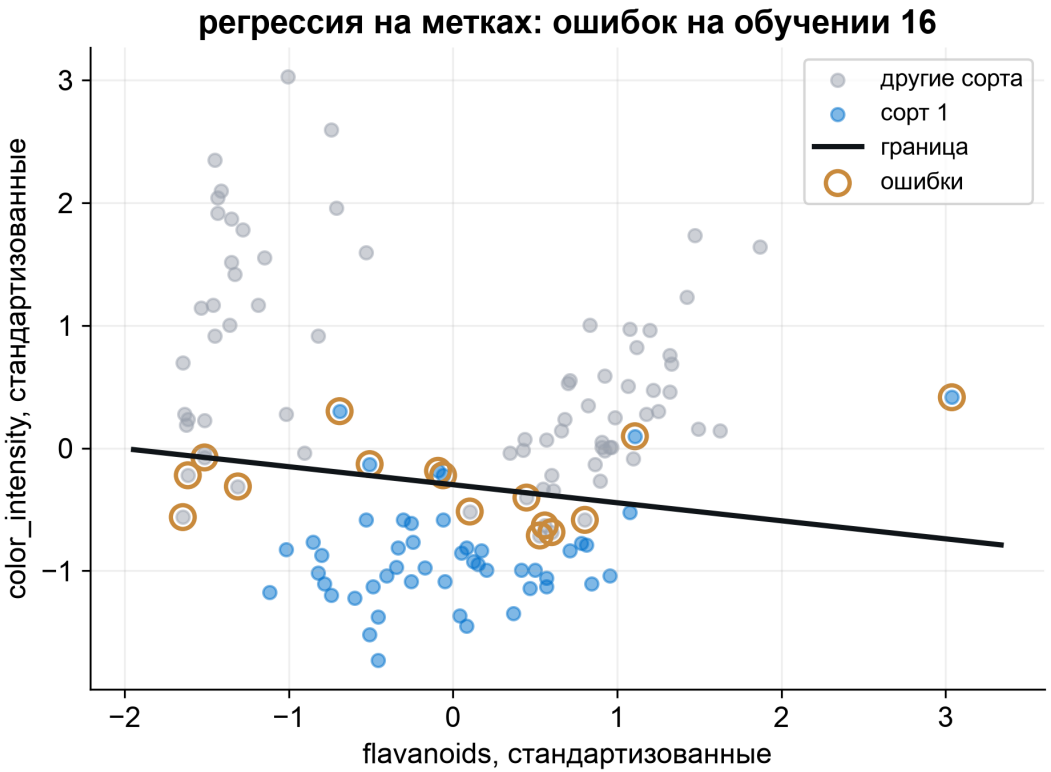


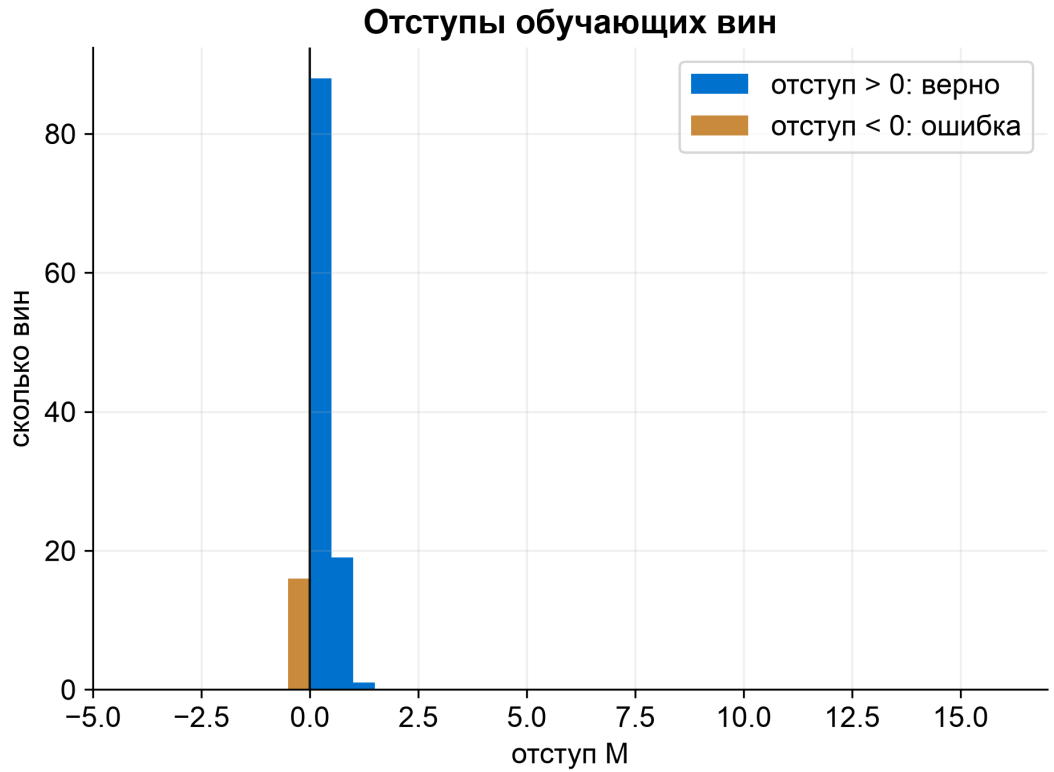
# Ответ — знак, уверенность — отступ

$$a(x) = \operatorname{sign}\left(\langle w, x\rangle + b\right)$$

$$M = y \cdot (\langle w, x\rangle + b), \qquad y \in \{-1, +1\}$$

# Первая модель: регрессия на метках



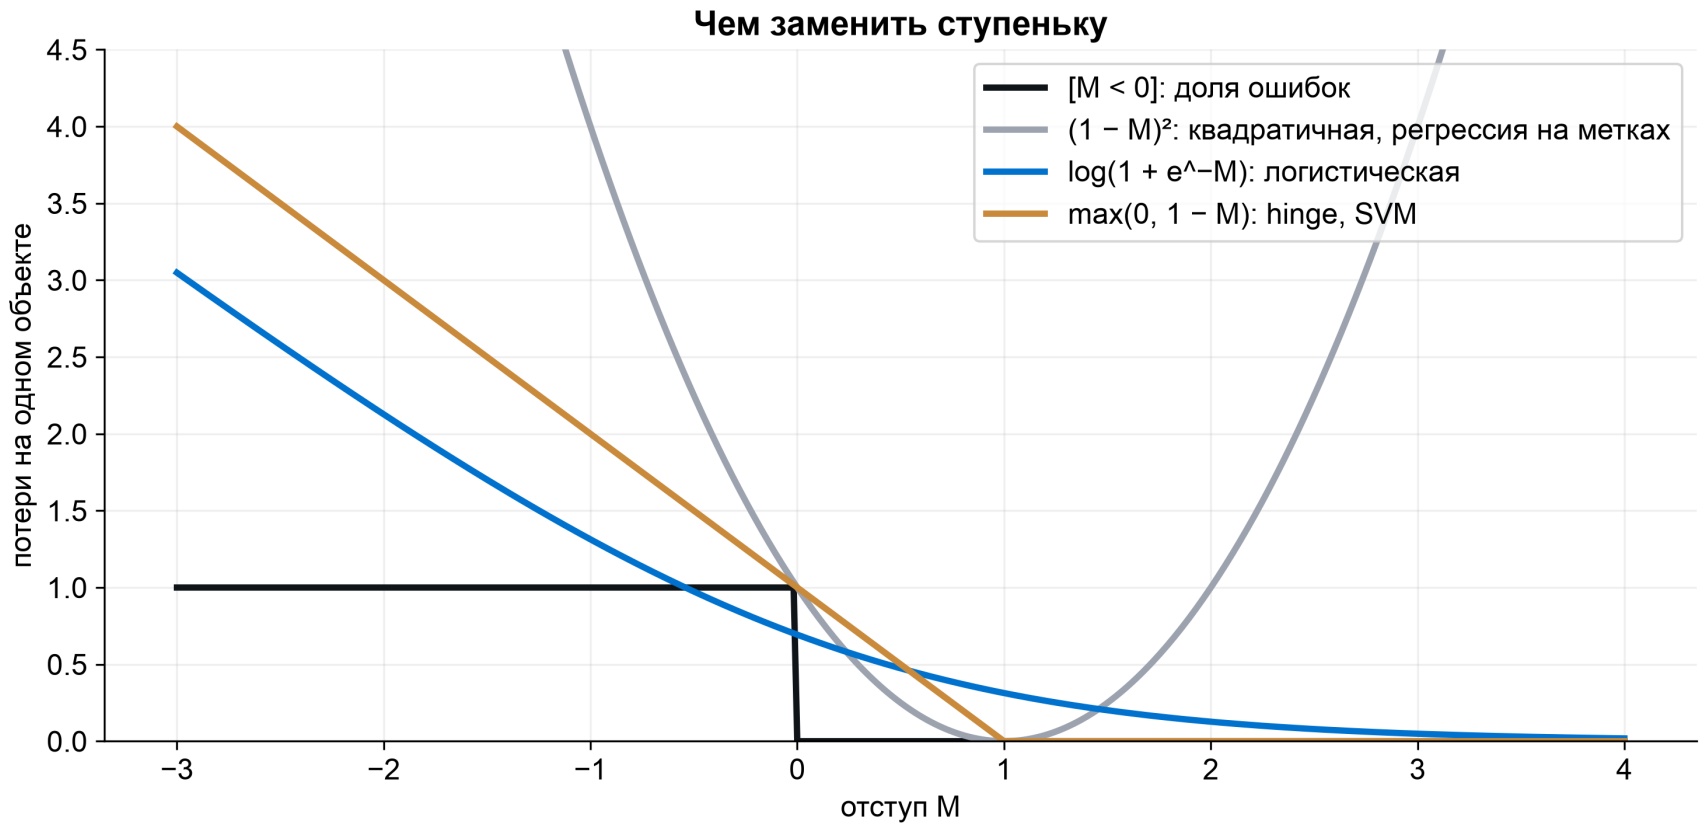
# 04

# Функции потерь через отступ

чем заменить ступеньку



# Четыре функции потерь от одного отступа



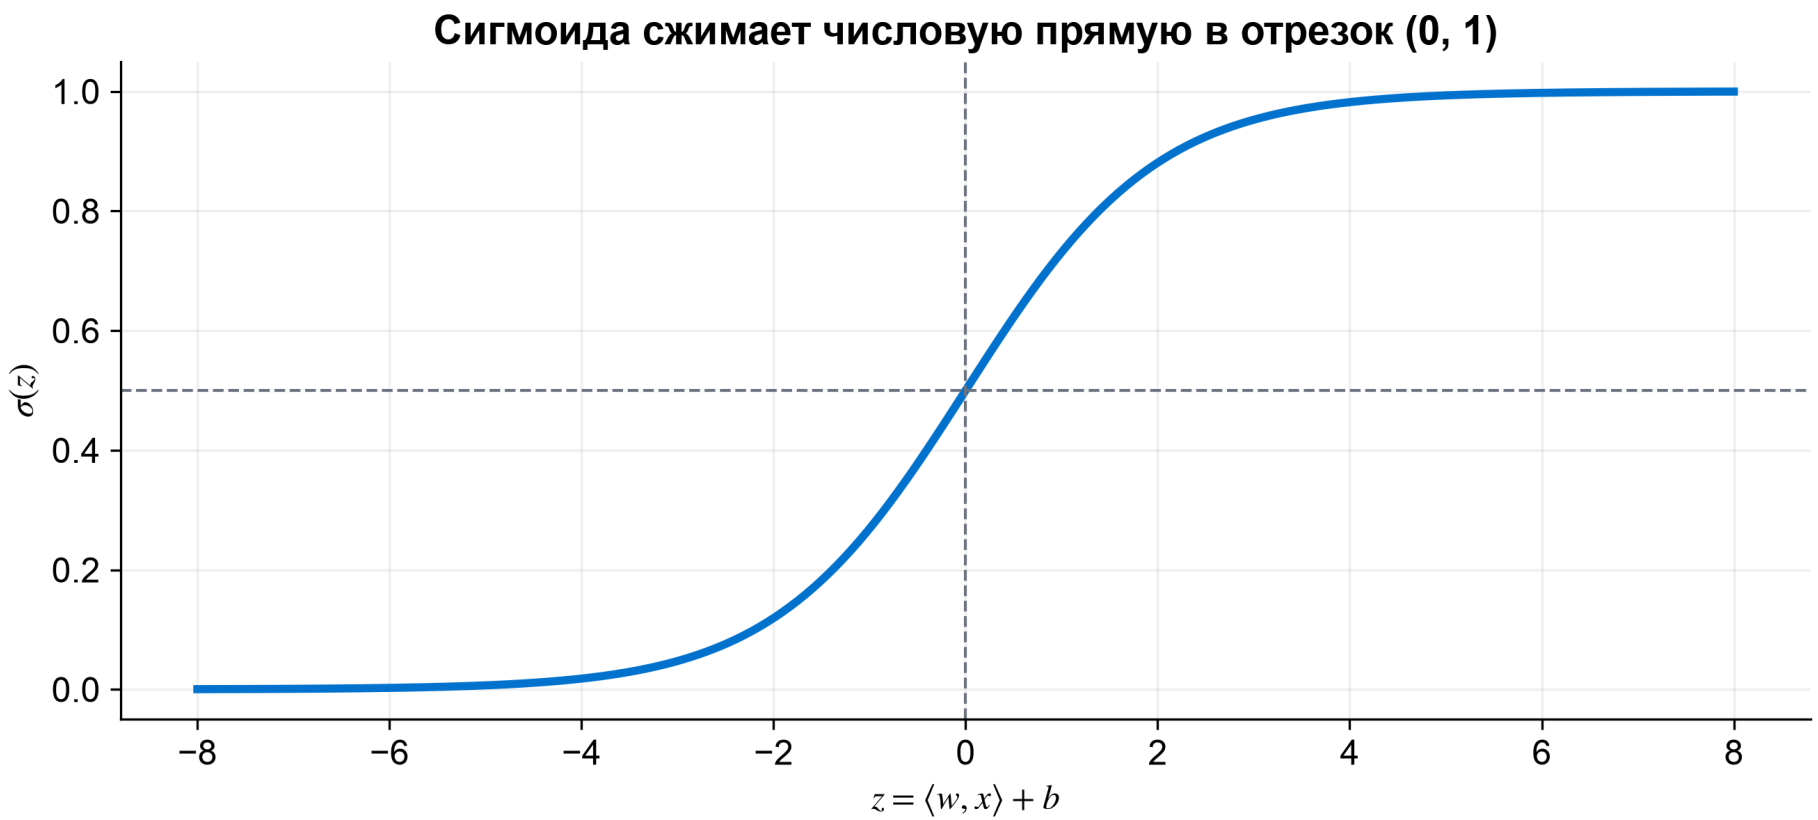
# 05

# Логистическая регрессия

та же логика, что с квадратами



# Сигмоида


Сигмоида сжимает числовую прямую в отрезок (0, 1)
1.0
0.8
0.6
0.4
0.2
0.0
$\sigma(z)$
−8
−6
−4
−2
0
2
4
6
8
$z = \langle w, x \rangle + b$

# Правдоподобие и log loss

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad p(y = 1 \mid x) = \sigma(\langle w, x \rangle + b)$$

$$L(w, b) = \prod_{i=1}^{n} p_i^{y_i} (1 - p_i)^{1 - y_i}$$

$$-\frac{1}{n} \log L = -\frac{1}{n} \sum_{i=1}^{n} (y_i \log p_i + (1 - y_i) \log(1 - p_i))$$

# 06

# Градиент и спуск

формулы для весов нет

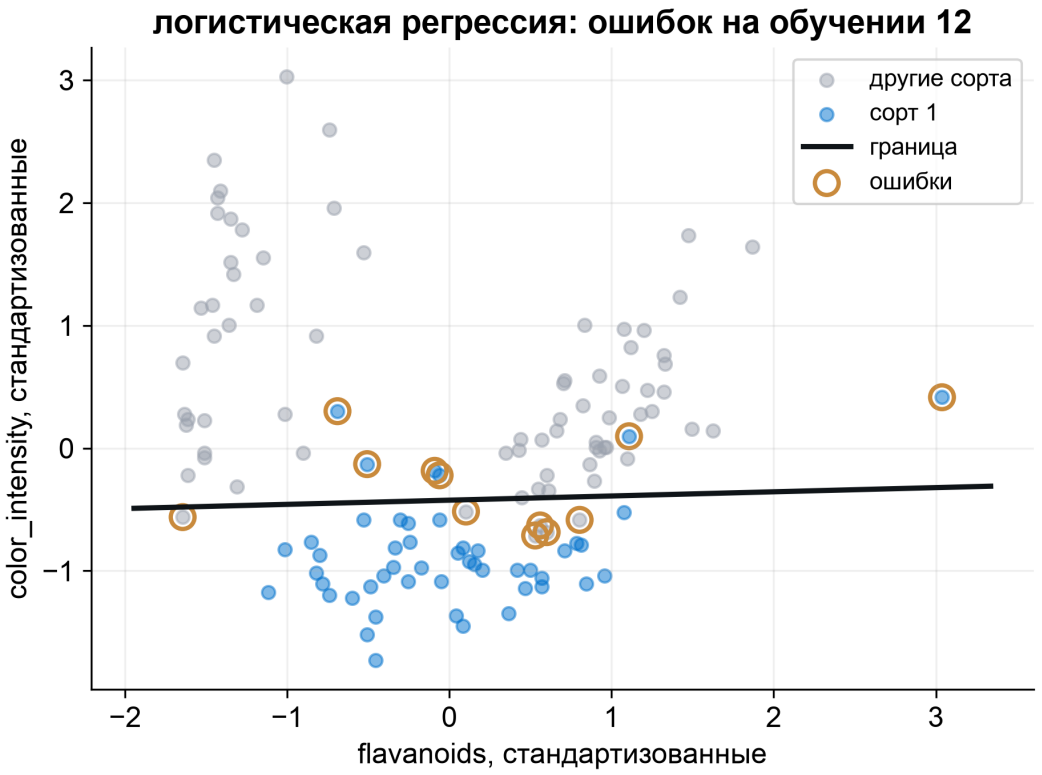


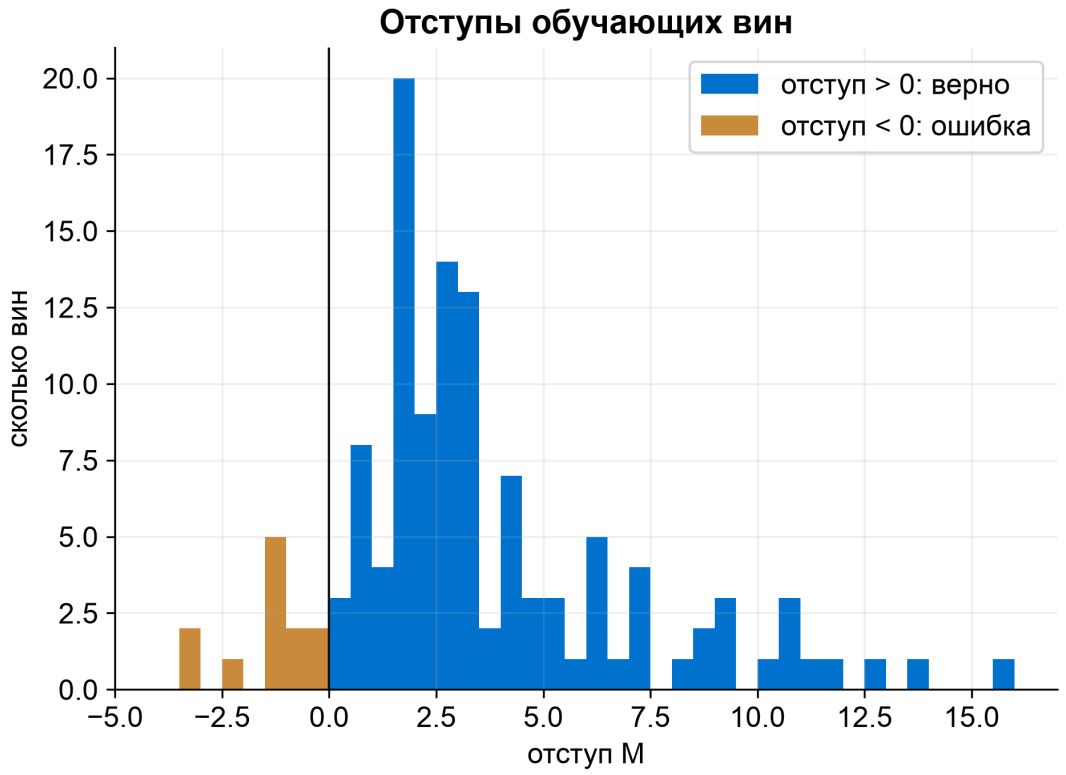
# Градиент log loss

$$\nabla_\theta L = \frac{1}{n} A^\top (p - y), \qquad p = \sigma(A\theta)$$

$$\theta \leftarrow \theta - \eta \nabla_\theta L$$

# Вторая модель: логистическая регрессия

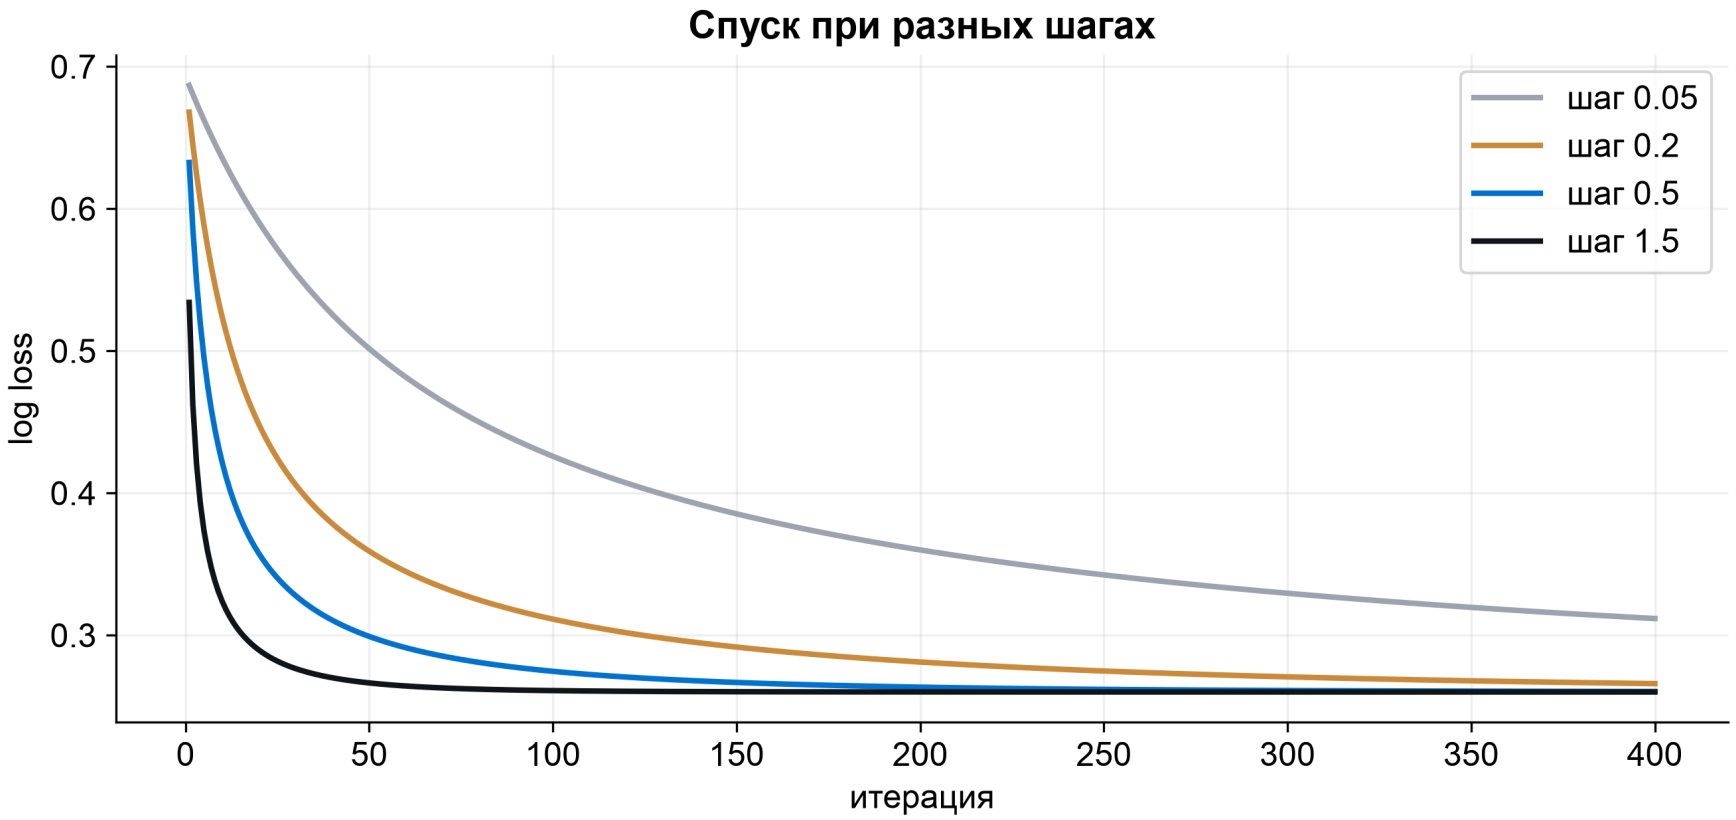


# Две модели, один тест

| модель | accuracy | precision | recall | ошибок на обучении |
|---|---|---|---|---|
| регрессия на метках | 0.815 | 0.731 | 0.864 | 16 |
| логистическая регрессия | 0.889 | 0.864 | 0.864 | 12 |

# Спуск при разных шагах



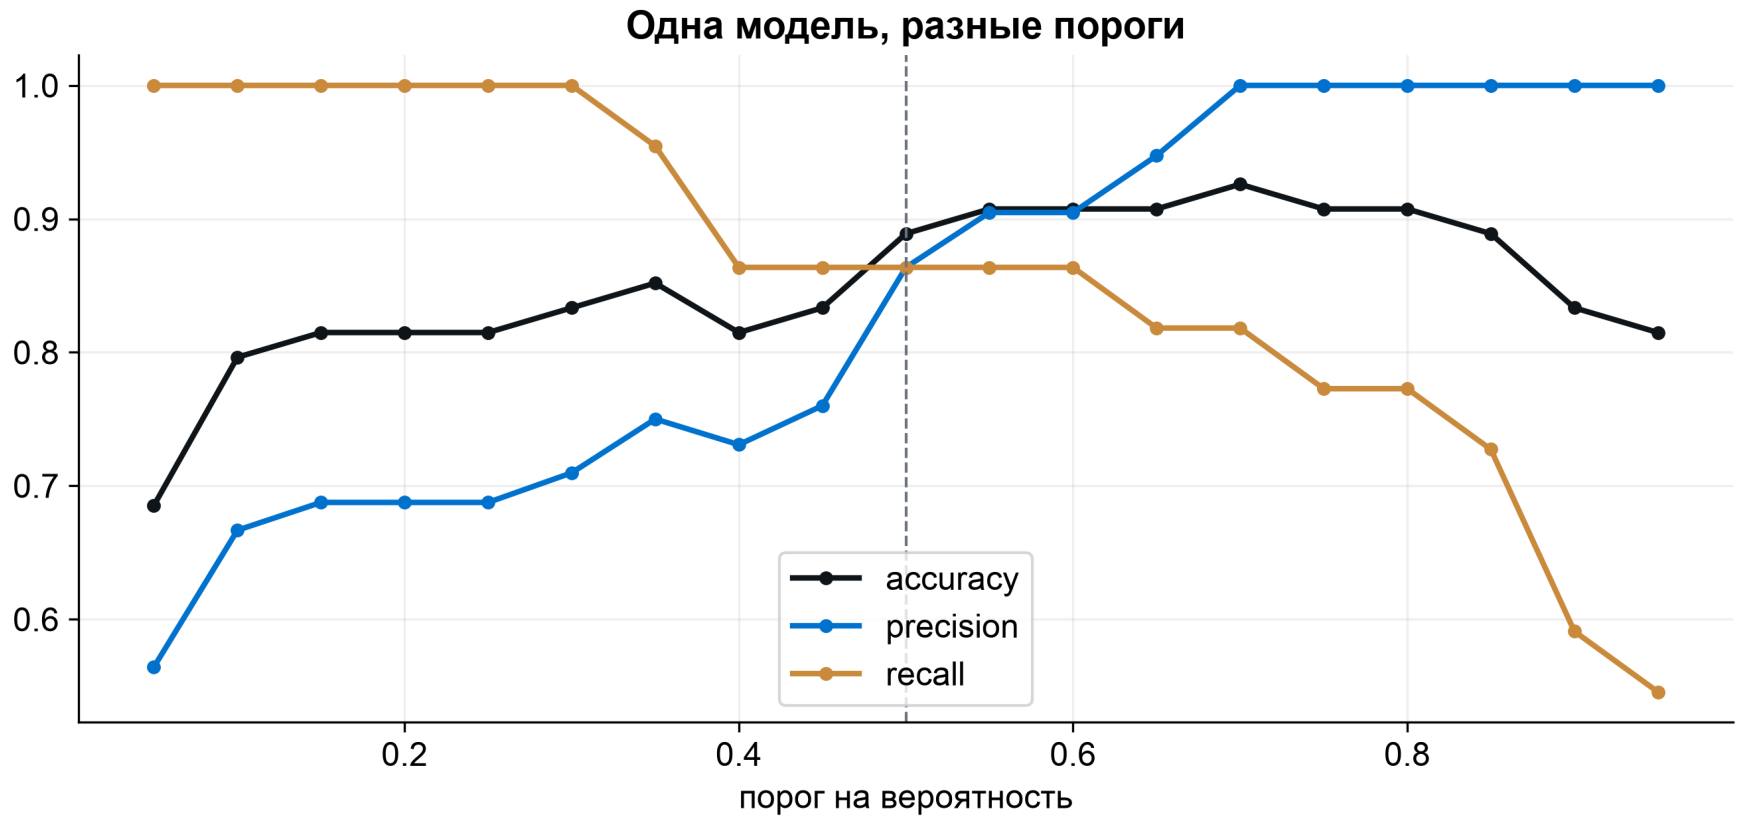
# 07

# Вероятности и порог

порог — не часть модели



# Одна модель, разные пороги



# 08

# Регуляризация

и здесь без нее нельзя



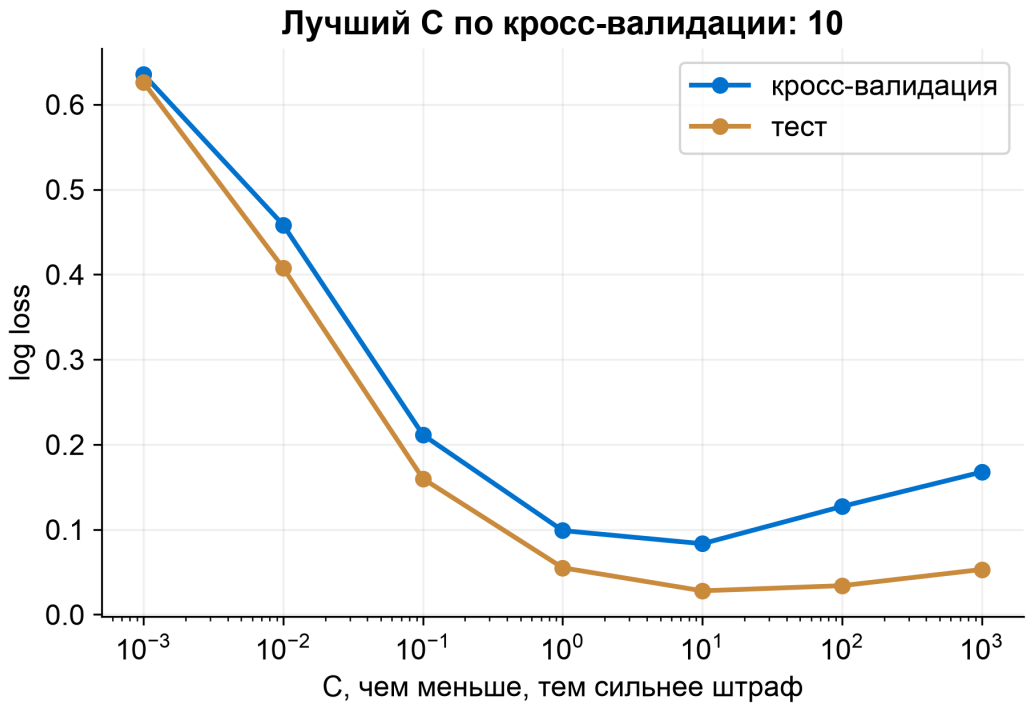
РАЗДЕЛИМЫЕ ДАННЫЕ

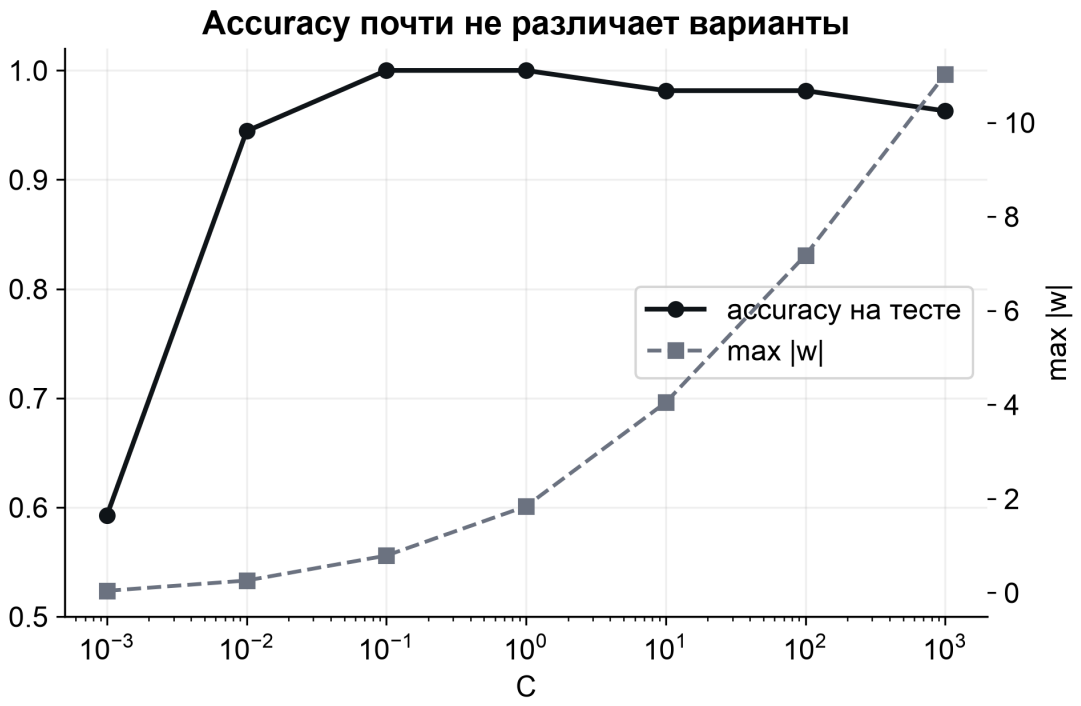
# 54.9

самый большой вес логистической регрессии без штрафа

accuracy на обучении 1.000, на тесте 0.963

# Выбор C по кросс-валидации



# 09

# Три сорта

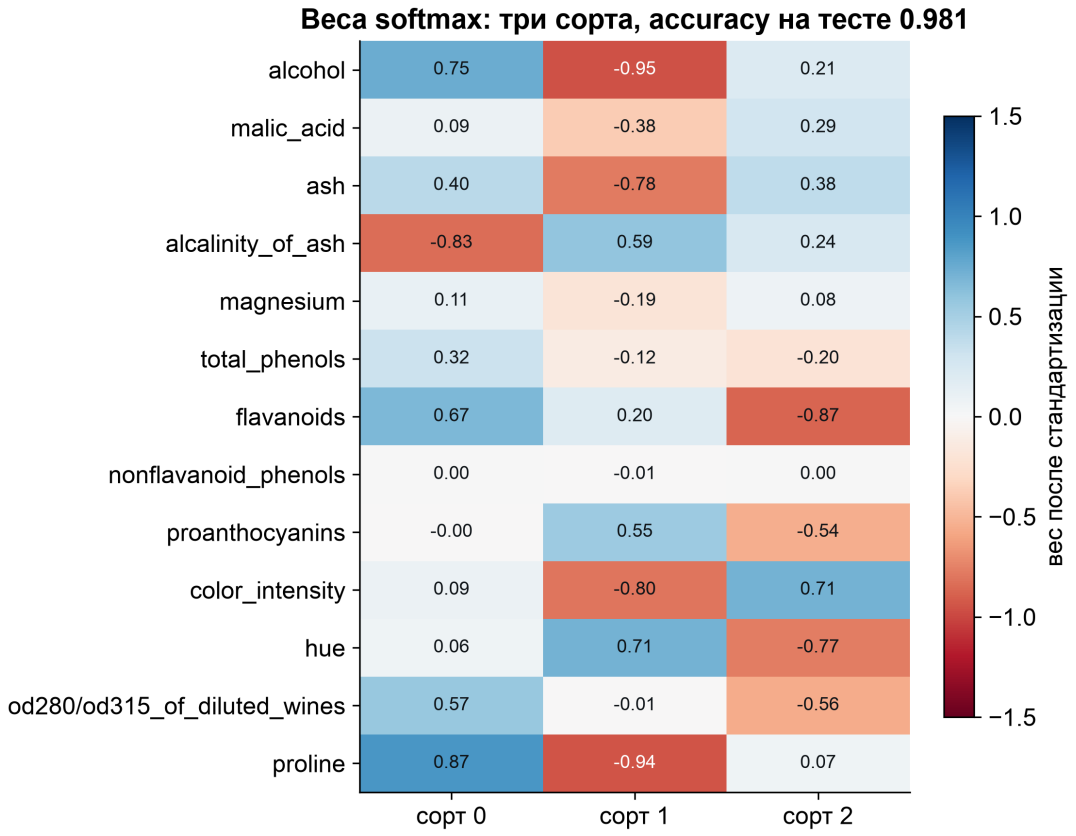
один против всех и softmax



# Softmax

$$p(y = k \mid x) = \frac{e^{\langle w_k, x \rangle}}{\sum_j e^{\langle w_j, x \rangle}}$$

# Что выучил softmax на трех сортах



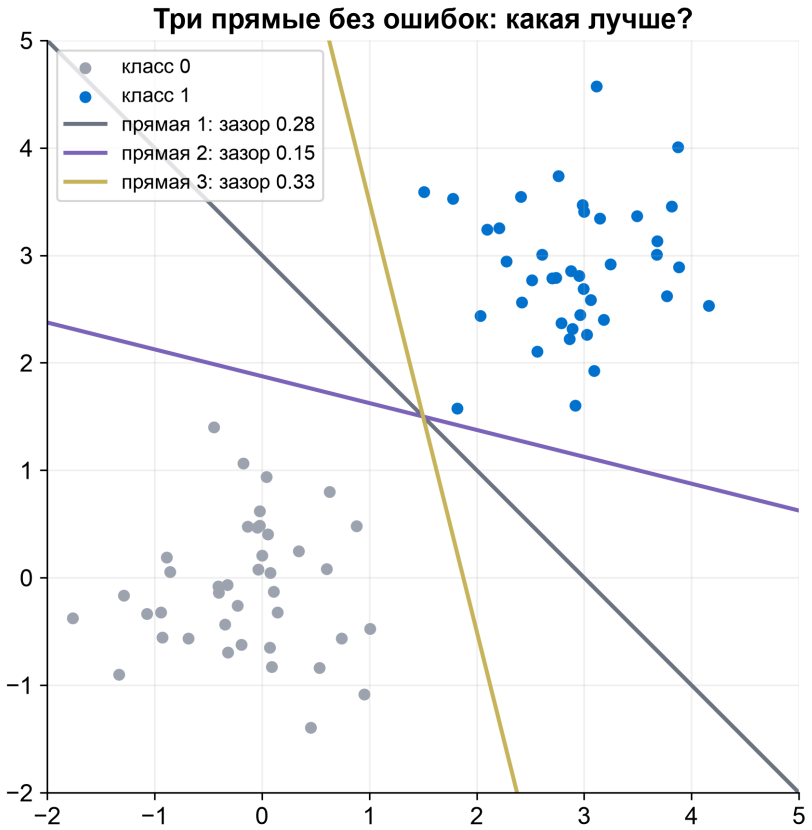
# 10

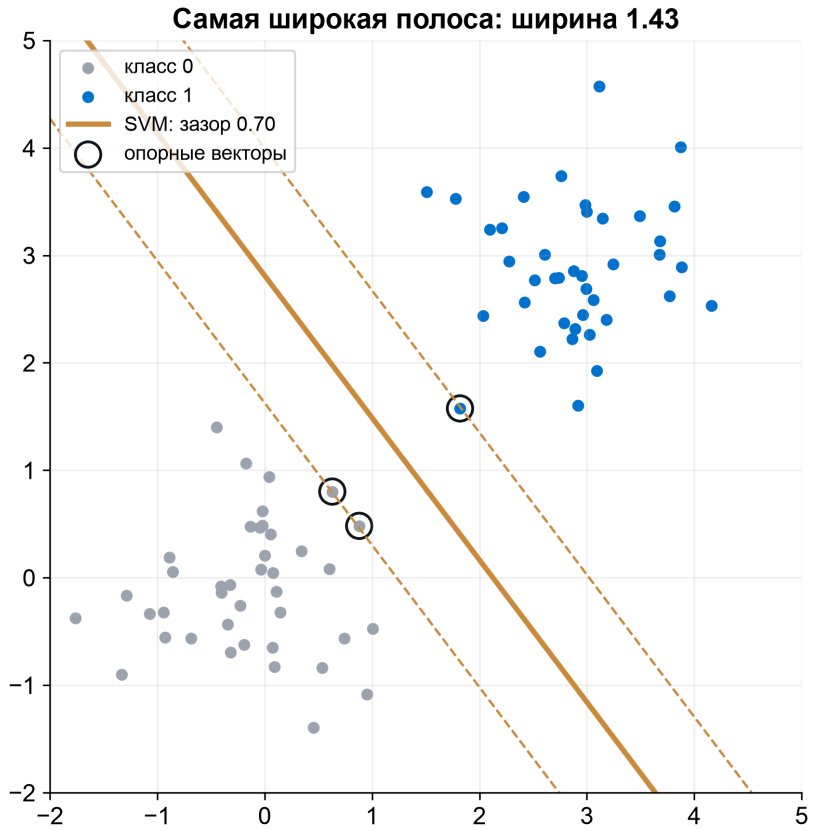
# Метод опорных векторов

какую прямую выбрать



# Прямых без ошибок много, зазор у них разный



# Полоса, hinge и C

$$\langle w, x\rangle + b = \pm 1, \qquad \text{width} = \frac{2}{\|w\|}$$

$$\frac{1}{n}\sum_{i=1}^{n} \max(0,\ 1 - M_i) + \frac{1}{2C}\|w\|^2 \to \min_{w,\ b}$$

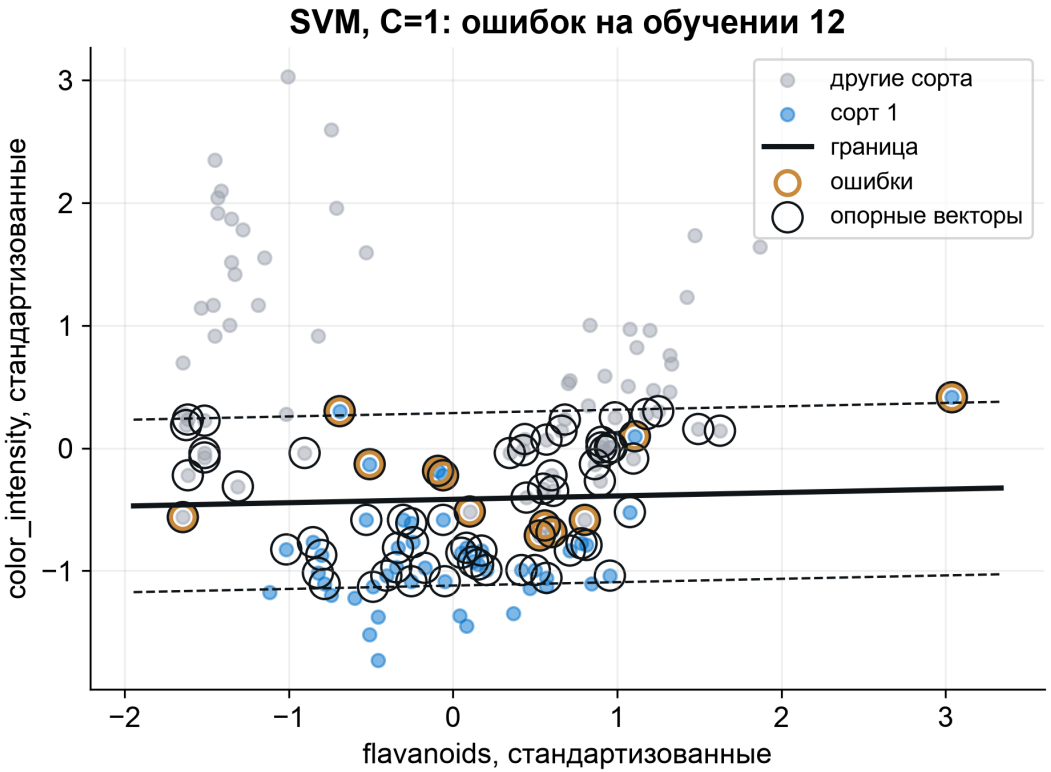
Ширина полосы 2/‖w‖: широкая полоса — маленькая норма

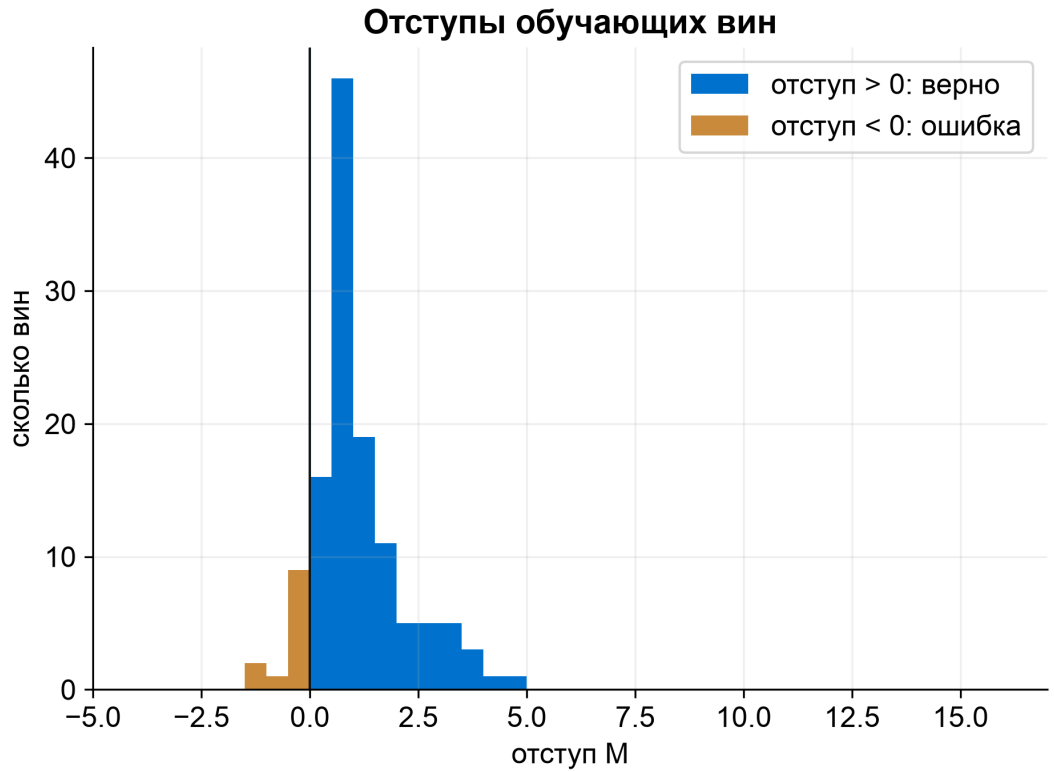
Разделимый случай: минимум ‖w‖ при условии M ≥ 1 для всех объектов

Неразделимый: за нарушение платим max(0, 1 − M) — это hinge

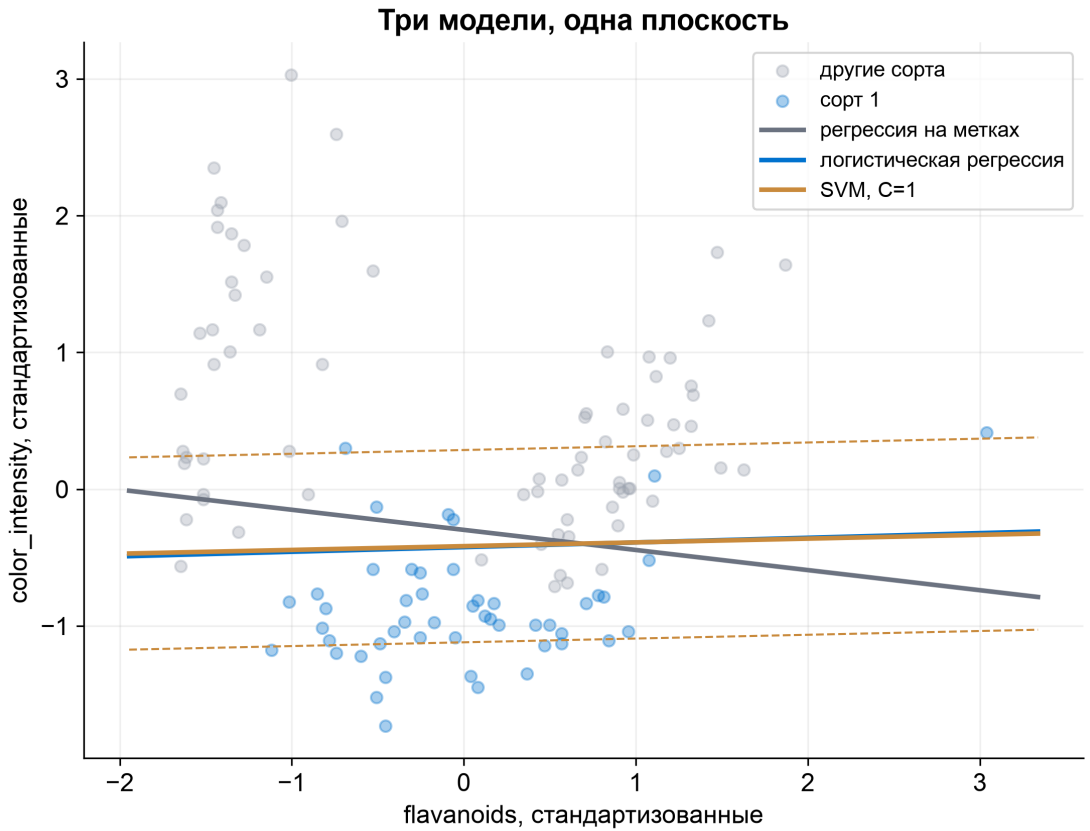
Опорные векторы — все объекты с M ≤ 1, только они определяют границу

# Третья модель: SVM



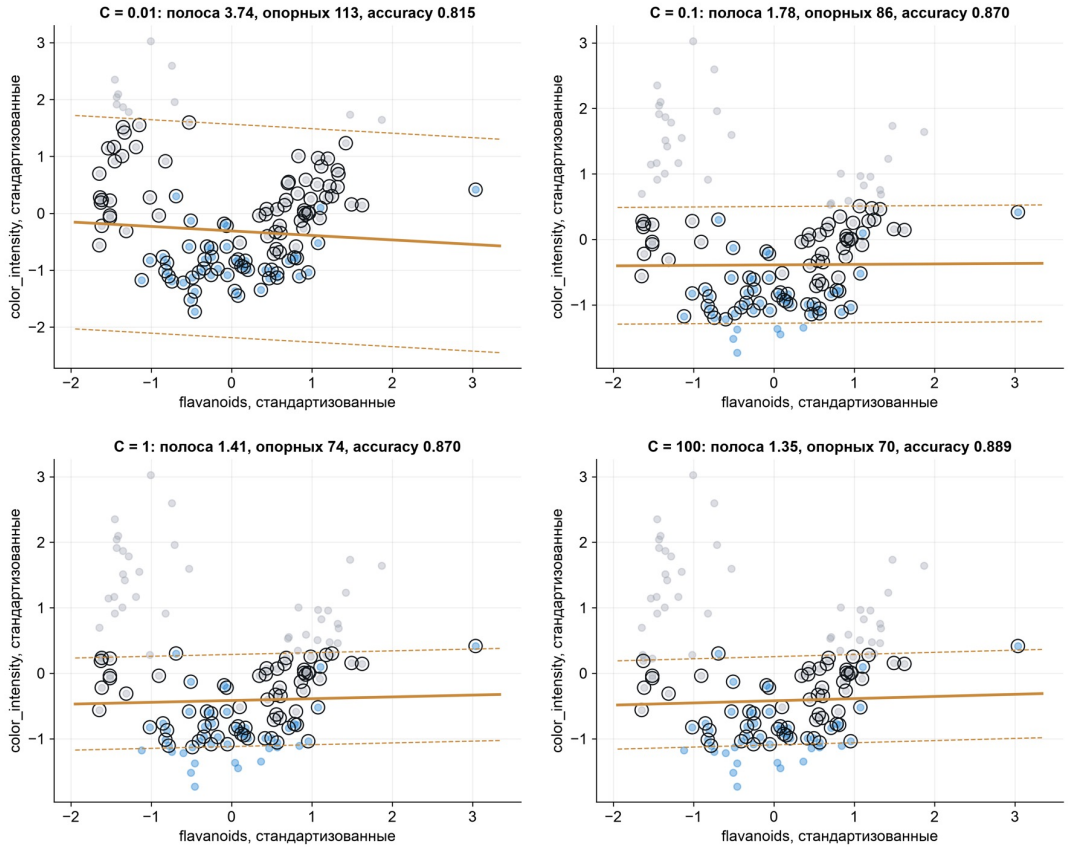
# Три модели, одна плоскость



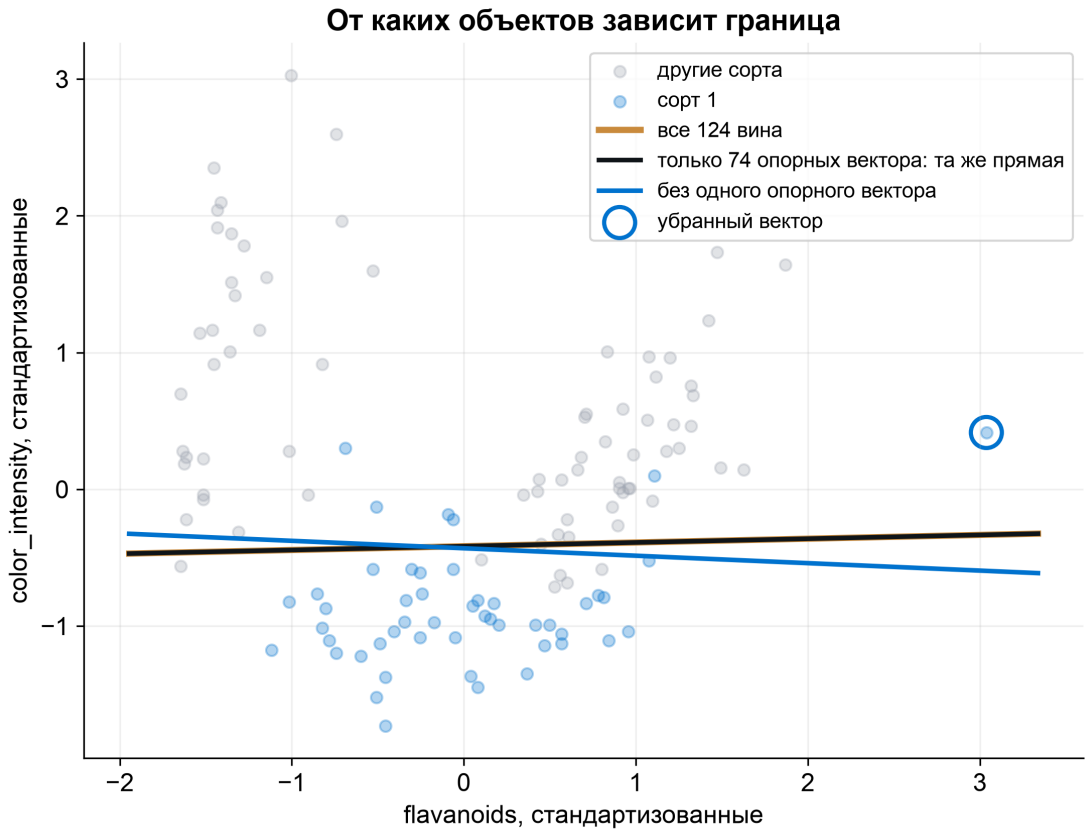
# Три модели, один тест

| модель | accuracy | precision | recall | ошибок на обучении |
|---|---|---|---|---|
| регрессия на метках | 0.815 | 0.731 | 0.864 | 16 |
| логистическая регрессия | 0.889 | 0.864 | 0.864 | 12 |
| SVM, C=1 | 0.870 | 0.826 | 0.864 | 12 |

# Что делает C


C = 0.01: полоса 3.74, опорных 113, accuracy 0.815
C = 0.1: полоса 1.78, опорных 86, accuracy 0.870
C = 1: полоса 1.41, опорных 74, accuracy 0.870
C = 100: полоса 1.35, опорных 70, accuracy 0.889
color_intensity, стандартизованные
flavanoids, стандартизованные

# От каких объектов зависит граница



# Одна идея на два занятия



# К следующему занятию




- Cross validation. BVD, лекция 5 Лектория ФПМИ
  https://www.youtube.com/watch?v=-taRv4WTUbo
- Лабораторная домашняя: прислать мне в личные сообщения до 26 сентября
- Завести аккаунт на Hugging Face: на следующем занятии выдается первая домашняя работа